Mondragon Unibertsitatea

Pipeline de análisis de datos

Mikel Martín
Andoni González
Javier Encinas

Qué hemos hecho



Tres preguntas sobre 16.376 personajes de Marvel

- ¿Cómo se reparten héroes y villanos?
- ¿Cuándo debutaron más personajes?
- ¿Quién aparece más y quién sobrevive?

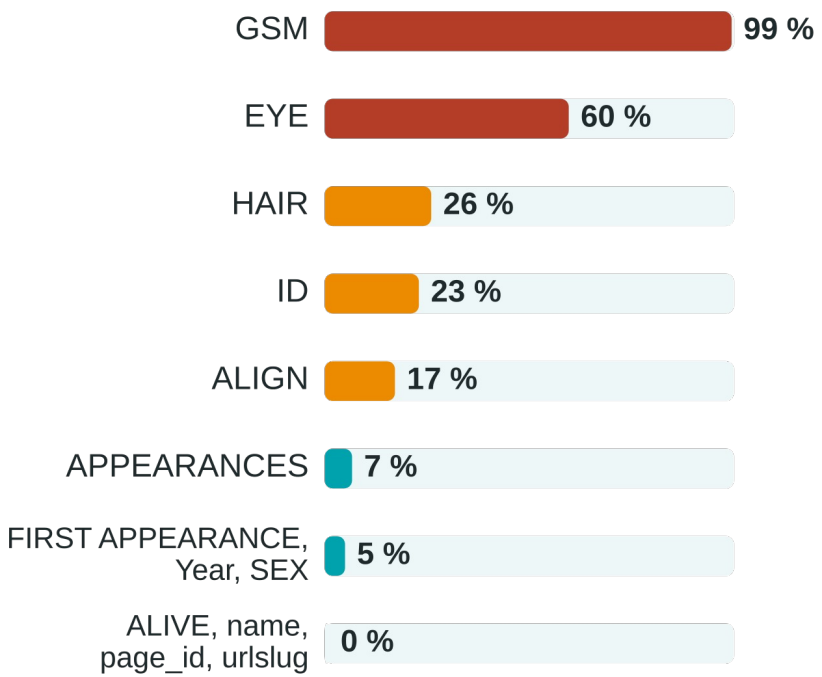
El dataset

16.376 personajes (filas)

13 columnas en el CSV

5 columnas usadas: name, align, alive, appearances, year

Valores nulos (% de 16.376 filas)



1

Desarrollo del pipeline

Cómo está hecho

Arquitectura

main.py
coordina el flujo con try / except / else / finally

cargador.py

Cargador
lee el CSV
valida columnas y tipos

limpiador.py

Limpiador
7 pasos de limpieza
informe antes / después

analizador.py

AnalizadorBase
validar_columnas(*cols)
filtrar(**condiciones)

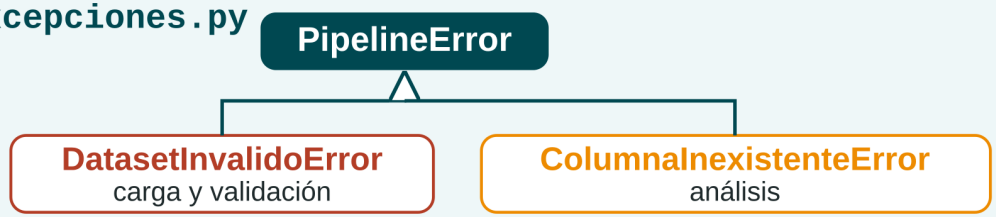
hereda de

AnalizadorMarvel
super().__init__(df)
8 métricas de Marvel

visualizador.py

VisualizadorMarvel
5 gráficos → resultados/

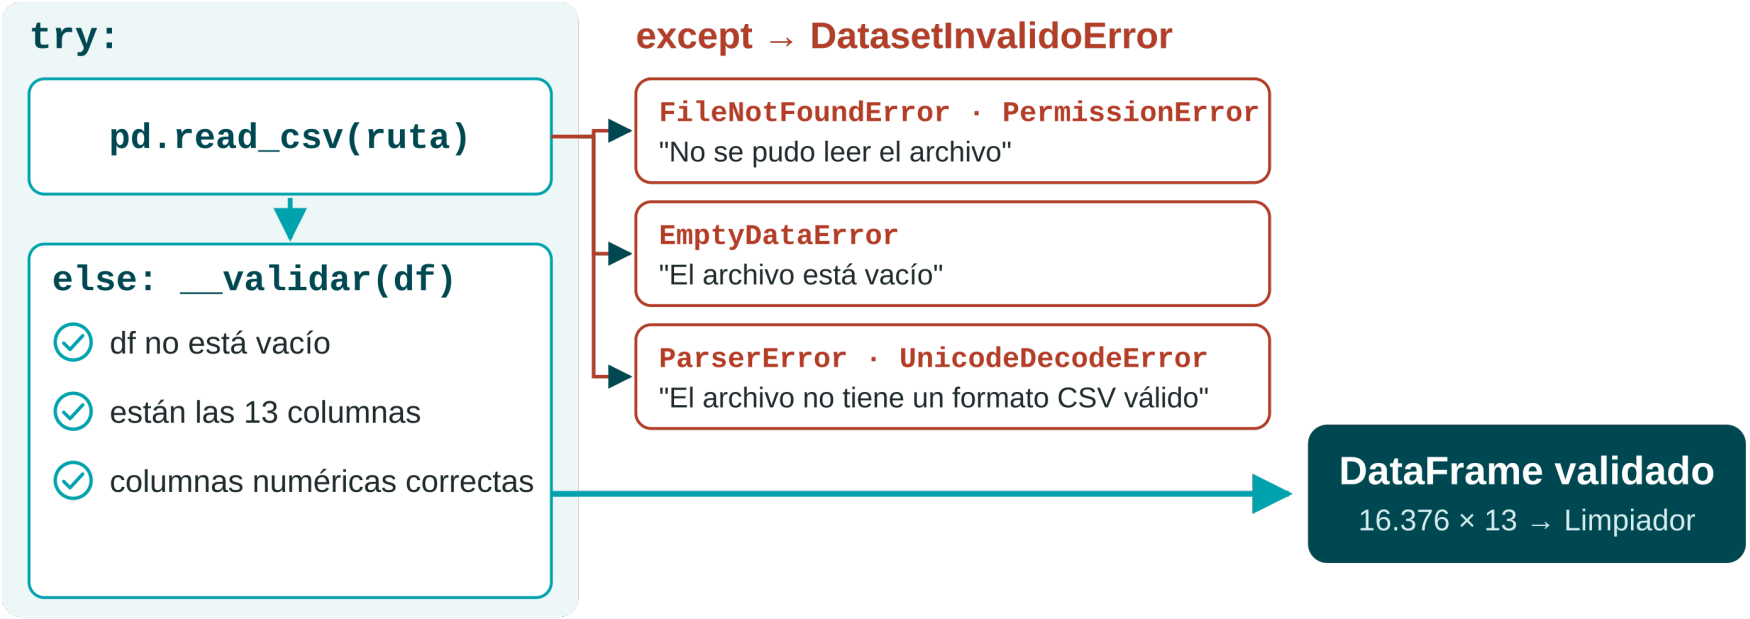
excepciones.py



utilidades.py

funciones auxiliares
reutilizables, sin estado

Carga y validación



- Si algo falla al leer o validar, el pipeline se detiene con un mensaje claro

Limpieza en siete pasos

1	2	3	4	5	6	7
eliminar duplicados	decodificar nombres	normalizar columnas	normalizar categorias	limpiar vacias	limpiar tuplas	convertir fecha

Filas	Columnas	Nulos en texto	Tipos
16.376 → **16.373**	13 → **12**	38.571 → **0**	float, str ▼ **Int64, datetime**

Análisis: tres técnicas

Estadísticas

Contar y medir

cuántos hay de cada tipo

cuántas veces aparece cada uno

Agrupaciones

Juntar por categoría

debuts de cada año

media de héroes frente a villanos

Filtros

Quedarse con una parte

solo los villanos

solo los personajes vivos

2

Resultados

Qué hemos descubierto

Resultados de un vistazo

Estadísticas

¿Cuántos héroes y villanos hay?

6.720 villanos

4.636 héroes

¿Cuánto aparece un personaje?

mediana: 3 veces

máximo: 4.043

Agrupaciones

¿Qué año tuvo más debuts?

1993

554 personajes nuevos

¿Quién aparece más?

Spider-Man

4.043 apariciones

¿Aparecen más los héroes?

sí: 35 de media

villanos: 8

Filtros

¿Cuál es el villano más visto?

Doctor Doom

721 apariciones

¿Quién sobrevive más?

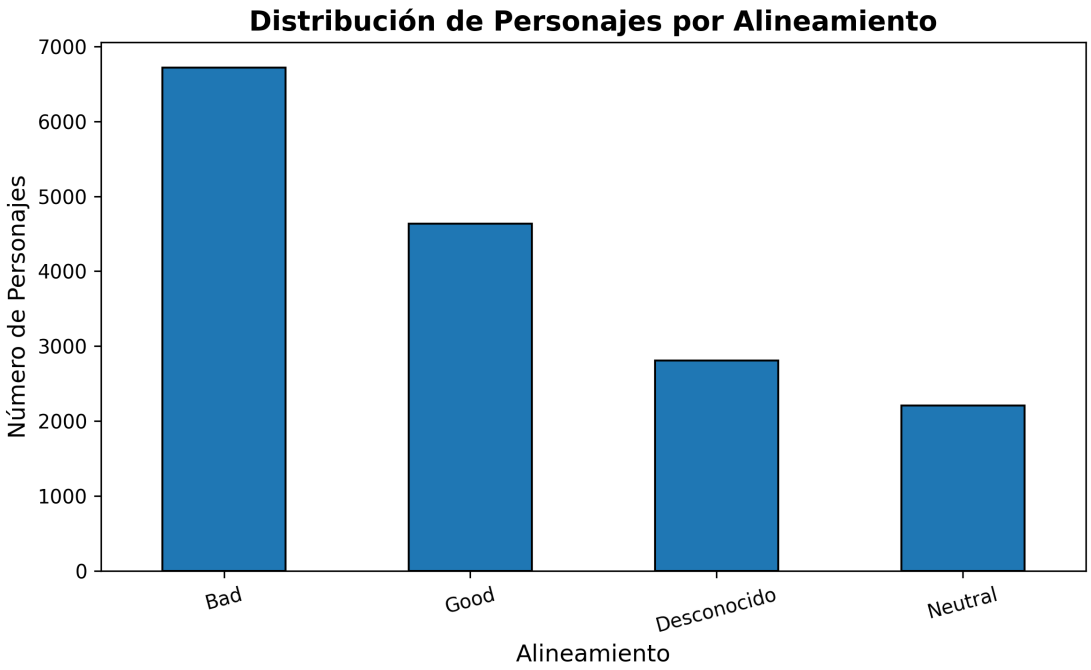
héroes 82 %

villanos 71 %

Más villanos que héroes

- **Bad** 41 %
- **Good** 28 %
- **Desconocido** 17 %
- **Neutral** 13 %

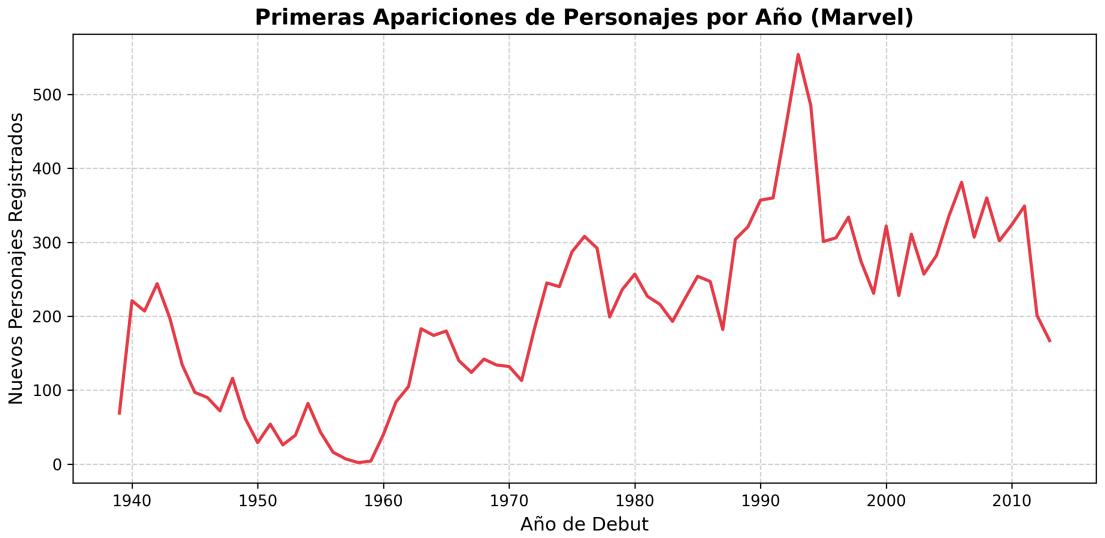
- Más de 2.000 villanos más que héroes



Los 90, la década de los debuts

- **Rango** 1939–2013
- **Pico** 1993: 554 debuts

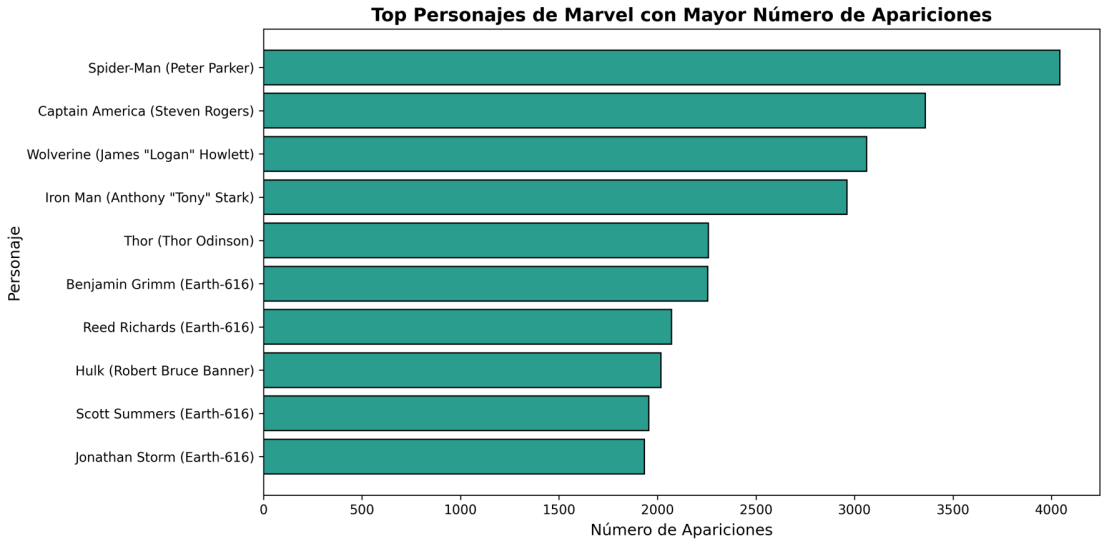
- Años 90: 3.657 personajes nuevos



Spider-Man, 4.043 apariciones

- **1.** Spider-Man 4.043
- **2.** Captain America 3.360
- **3.** Wolverine 3.061

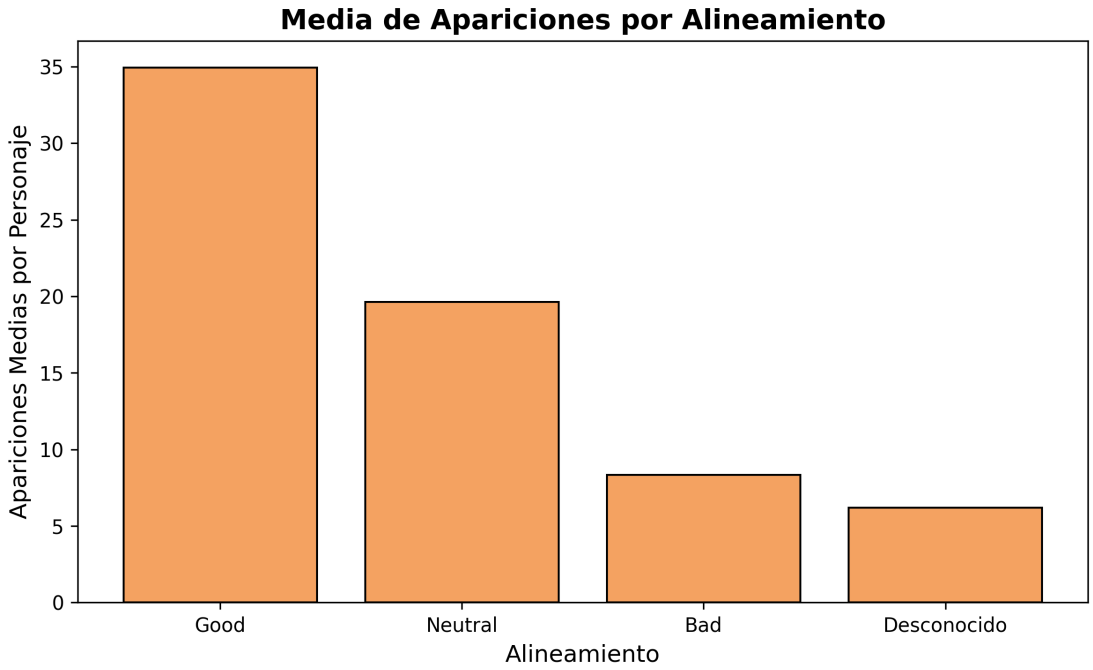
- La mediana del dataset es 3



Los héroes aparecen 4 veces más

- **Good** 34,9
- **Neutral** 19,6
- **Bad** 8,3

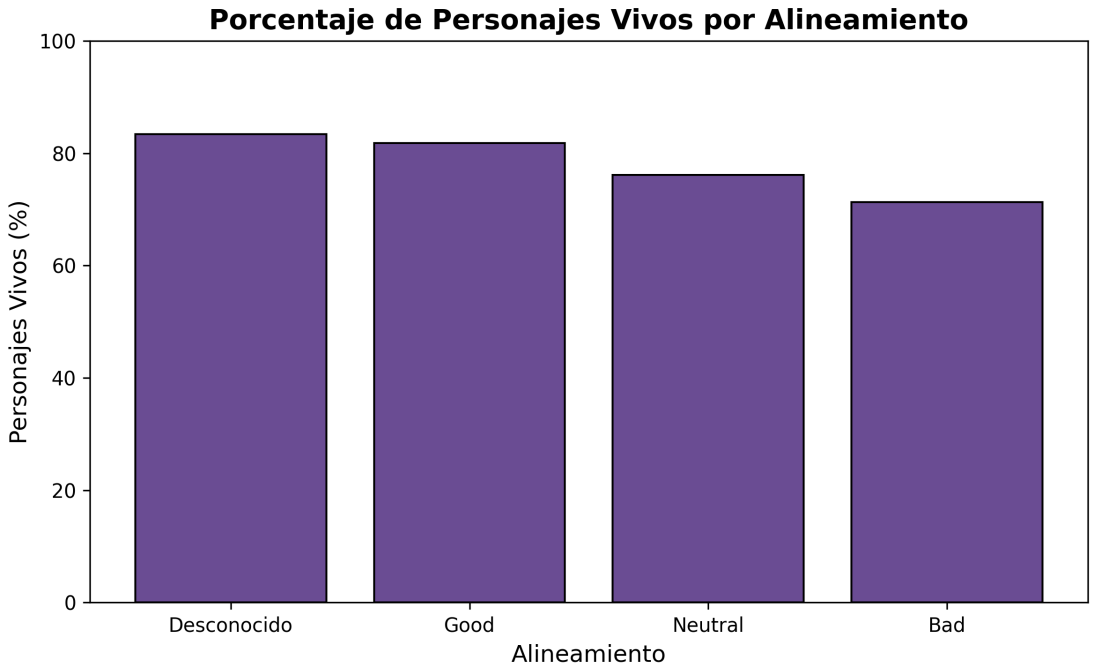
- Top villano: Doom, 721
- filtrar(align="Bad")



Supervivencia de héroes y villanos

- **Héroes vivos** 82 %
- **Villanos vivos** 71 %

- Casi 3 de cada 10 villanos han muerto
- filtrar(alive="Living")



Conclusiones

41 % / 28 %

villanos frente a héroes
6.720 Bad · 4.636 Good

×4

apariciones medias de un héroe
frente a un villano (34,9 / 8,3)

82 % / 71 %

héroes vivos frente a villanos vivos
casi 3 de cada 10 villanos mueren

Más villanos, pero los héroes aparecen más y sobreviven más.

Pocos personajes concentran casi todas las apariciones.

Los años 90 fueron el boom de creación de personajes.

Límites del análisis

Datos incompletos

17 % sin alineamiento y 7 % sin apariciones

Columnas inutilizables

GSM (99 % nulos) y EYE (60 %)

Rango temporal

los datos llegan solo hasta 2013

Describe, no explica

sabemos qué pasa, no por qué pasa

Mondragon Unibertsitatea

Muchas gracias

Repositorio del proyecto
github.com/andoni92/
marvel-dataset-analyzer